

Tržišta pažnje u religijskim digitalnim medijima

Mapiranje hrvatskog katoličkog digitalnog prostora

Šikić, Luka, Palić, Petra i Kovačić, Siniša

2026-02-27

Table of contents

Sažetak	1
1 Uvod	2
2 Pregled literature	3
3 Cilj i hipoteze istraživanja	4
4 Podaci i metode	6
4.1 Baza podataka DigiKat	6
4.1.1 Struktura podataka i ključne varijable	6
4.2 Klasifikacija aktera	7
4.3 Analitički pristup	8
5 Rezultati	9
5.1 Tržišna struktura i koncentracija (H1)	9
5.1.1 Mjere koncentracije	10
5.2 Institucionalni modaliteti pažnje (H2)	12
5.3 Sprega sentimenta i pažnje (H3)	14
5.4 Liturgijsko vremensko strukturiranje (H4)	16
5.5 Platformski specifična koncentracija (H5)	17
5.6 Sažetak testiranja hipoteza	18
6 Rasprava	19
Etički aspekti i dostupnost podataka	20
7 Zaključak	21
Literatura	21

Sažetak

U digitalnom dobu, obilje informacija stvara novu vrstu oskudice u kojoj pažnja postaje najvrjedniji resurs za religijske komunikatore. Ova studija primjenjuje okvir ekonomije pažnje na analizu hrvatskih katoličkih

digitalnih medija, pružajući prvo sustavno mapiranje nacionalnog religijskog digitalnog ekosustava. Koristeći bazu podataka DigiKat, koja obuhvaća više od 608.879 objava objavljenih između 2021. i 2025. godine na 8 platformi, ispituje distribuciju pažnje, modalitete angažmana, ulogu sentimenta, utjecaj liturgijskog kalendara i platformski specifične obrasce koncentracije. Pet hipoteza izvedenih iz teorije ekonomije pažnje i medijalizacije religije testirano je primjenom mjera nejednakosti, dekompozicije angažmana, neparametrijskih testova i vremenske analize. Rezultati potvrđuju da pažnja slijedi distribuciju po zakonu potencije s ekstremnom koncentracijom. Institucionalni akteri ne privlače samo manje ukupnog angažmana, već privlače kvalitativno drugačiju vrstu pažnje od neinstitucionalnih komunikatora. Negativni sentiment pojačava privlačenje pažnje, ali nejednako po tipovima aktera. Katolički liturgijski kalendar strukturira ritam objavljivanja povrha sekularnih vremenskih obrazaca, a razina koncentracije pažnje varira po platformama. Nalazi imaju praktične implikacije za katoličke komunikatore te doprinose razumijevanju funkcioniranja religije unutar ekonomije pažnje.

Glavne riječi: ekonomija pažnje, religijska komunikacija, digitalni mediji, Katolička crkva, Hrvatska

1 Uvod

U digitalnom dobu, obilježje informacija stvara novu vrstu oskudice u kojoj pažnja postaje najvrjedniji resurs. Kako je Herbert Simon (1971) istaknuo, obilježje informacija stvara siromaštvo pažnje, osobito u kontekstima gdje se različiti akteri natječu za ograničenu percepciju publike. Koncept ekonomije pažnje, kasnije razrađen od autora poput Davenporta i Becka (2001), polazi od pretpostavke da je pažnja ograničen resurs koji cirkulira na tržištu gdje ponuda sadržaja daleko nadmašuje potražnju. U digitalnim medijskim ekosustavima ta dinamika dovodi do koncentracije moći kod velikih platformi i aktera, stratifikacije prema razini angažmana te naglasaka na emocionalno nabijenom sadržaju koji potiče interakcije. U religijskim digitalnim medijima ova logika oblikuje tržišta pažnje u kojima institucije, laici, influenceri i grassroots inicijative konkuriraju za angažman korisnika na društvenim mrežama, YouTubeu i web portalima (Campbell, 2022; Van Dijck, 2018). Unatoč rastućoj prisutnosti religijskih aktera u digitalnom prostoru, primjena ekonomije pažnje na neprofitne i religijske kontekste ostaje nedovoljno istražena.

Religijski digitalni ekosustavi predstavljaju hibrid tradicije i tehnologije, obuhvaćajući formalne institucionalne kanale, poput Hrvatske biskupske konferencije, ali i neovisne aktere, uključujući digitalne influencere i medijske portale koji proizvode duhovni, edukativni ili zabavni sadržaj (Hoover, 2006; Hjarvard, 2008). U Hrvatskoj, gdje se prema popisu stanovništva iz 2021. godine oko 79 % građana identificira kao katolici, Katolička crkva ostaje snažan kulturni i društveni akter, no njezina digitalna prisutnost nije nužno proporcionalna demografskoj dominaciji. Digitalni mediji otvaraju prostor za evangelizaciju, pastoralnu komunikaciju i zajedničko oblikovanje religijskih narativa, ali istodobno izlažu vjerske aktere algoritamskim logikama koje favoriziraju viralnost i angažman nad institucionalnim autoritetom.

Hrvatski katolički digitalni prostor obuhvaća više od 608.879 objava prikupljenih u razdoblju od 2021. do 2025. godine u okviru baze DigiKat, pružajući jedinstvenu empirijsku osnovu za analizu distribucije pažnje. Dosadašnja analiza pokazuje izrazitu koncentraciju angažmana, pri čemu mali broj aktera kontrolira većinu pažnje, što potvrđuju visoke vrijednosti Gini koeficijenta i omjera koncentracije (Pedersen i sur., 2021; Wojtowicz i Loewenstein, 2020). Ovi obrasci odgovaraju zakonima potencije karakterističnima za ekonomiju pažnje, prema kojima se pažnja akumulira u ograničenom broju dominantnih aktera (Falkinger, 2007; Latham, 2006). U religijskom kontekstu, međutim, pažnja poprima dodatnu duhovnu dimenziju jer angažman korisnika ne predstavlja samo ekonomski resurs nego i oblik religijske participacije i identiteta (Franck, 2019; Wojtowicz i Loewenstein, 2020). Emocionalni faktori i vremenski ritmovi, uključujući liturgijski kalendar,

dodatno oblikuju dinamiku angažmana, često favorizirajući vizualno privlačan i emotivno snažan sadržaj (Pedersen i sur., 2021; Aggarwal i sur., 2023).

Polazeći od ovih teorijskih i empirijskih uvida, ova analiza u fokus stavlja kako se pažnja raspodjeljuje između institucionalnih i neovisnih aktera u hrvatskim katoličkim digitalnim medijima, koju ulogu imaju emocionalni i vremenski faktori u dinamici angažmana te kako koncentracija pažnje utječe na religijsku komunikacijsku praksu. Metodološki pristup kombinira kvantitativne analize, uključujući Gini koeficijente, dekompoziciju angažmana, analizu sentimenta i neparametrijske testove, s interpretacijama utemeljenima u teoriji ekonomije pažnje i medijizacije religije (Van Dijck, 2018; Campbell, 2022).

Cilj ovog istraživanja je trostruk. Prvo, nastoji se pružiti sustavno mapiranje nacionalnog religijskog digitalnog ekosustava koristeći bazu DigiKat, koja obuhvaća više od 608.879 objava raspoređenih na 8 platformi u razdoblju od 2021. do 2025. godine. Drugo, rad ispituje primjenjivost ključnih hipoteza ekonomije pažnje u nekomercijalnom religijskom kontekstu, proširujući ih novim dimenzijama poput modaliteta angažmana, uloge sentimenta i platformski specifične koncentracije. Treće, istraživanje nastoji identificirati praktične implikacije za katoličke komunikatore, s posebnim naglaskom na institucionalna ograničenja i prilagodbu ritmovima liturgijske godine. Time rad doprinosi interdisciplinarnom području religijske komunikacije, medijskih studija i digitalne sociologije pružajući empirijski utemeljeno razumijevanje funkcioniranja religije unutar ekonomije pažnje. Istodobno, nalazi imaju šire komparativne implikacije jer pokazuju kako ekonomski i psihološki mehanizmi pažnje oblikuju religijsku participaciju u online prostoru (Wojtowicz i Loewenstein, 2020; Van Dijck, 2018).

2 Pregled literature

Koncept ekonomije pažnje razvija se kao odgovor na strukturne promjene u društvima obilježenima obiljem informacija i ograničenim kognitivnim kapacitetima pojedinaca. Herbert Simon (1971) istaknuo je da obilje informacija ne povećava kognitivne resurse primatelja, već stvara oskudicu pažnje koja postaje ključni ograničeni resurs u suvremenim komunikacijskim i organizacijskim sustavima. Ova temeljna ideja kasnije je razvijena u radovima koji pažnju promatraju kao valutu digitalne ekonomije, u kojoj akteri, od institucionalnih organizacija do pojedinačnih kreatora sadržaja, konkuriraju za vidljivost i angažman publike. Goldhaber (1997) dodatno argumentira da internet označava prijelaz iz ekonomija temeljenih na materijalnim dobrima u ekonomiju u kojoj pažnja postaje primarna valuta, akumulirajući se kroz interakcije i viralno širenje sadržaja, dok njezina oskudica generira hijerarhije utjecaja među akterima. Davenport i Beck (2001) ističu da koncentracija pažnje ima ključnu ulogu u organizacijskim procesima, pri čemu preopterećenje informacijama dovodi do fragmentacije fokusa i smanjene sposobnosti duboke analize. Falkinger (2007) formalizira natjecanje za pažnju kroz funkcije filtriranja i prioritizacije signala, pokazujući kako se distribucija pažnje podvrgava zakonima potencije, dok Lanham (2006) ističe retoričku i estetsku dimenziju pažnje; u preobilju informacija, oblik i stil postaju ključni za privlačenje publike, evolvirajući pritom ekonomiju pažnje u ekonomiju estetike i performativnosti. Recentne interdisciplinarne sinteze, poput rada Francka (2019), integriraju psihološke i ekonomske perspektive, pokazujući kako pažnja objašnjava odstupanja od klasičnih ekonomskih modela i kako algoritamska selekcija sadržaja oblikuje hijerarhije utjecaja u digitalnim ekosustavima.

Važno je pritom istaknuti da pažnja nije jednodimenzionalan konstrukt. Davenport i Beck (2001) razlikuju zarobljenu i dobrovoljnu pažnju, dok Wojtowicz i Loewenstein (2020) naglašavaju ulogu znatiželje kao specifičnog modaliteta pažnje koji pokreće aktivno traženje informacija. U kontekstu digitalnih platformi, različiti oblici angažmana, od pasivnog odobravanja (lajk) preko aktivnog izražavanja (komentar) do distribucijskog čina (dijeljenje), predstavljaju kvalitativno različite modalitete pažnje s različitim kognitivnim troškovima i komunikacijskim funkcijama. Ova distinkcija ostaje nedovoljno iskorištena u empirijskim istraživanjima koja tipično operiraju s agregiranim mjerama angažmana, zanemarujući time unutarnju strukturu pažnje.

U institucionalnom okviru, Van Dijck (2018) opisuje digitalne platforme kao tržišta pažnje koja posreduju između korisnika i sadržajnih kreatora, oblikujući obrasce vidljivosti, društvene nejednakosti i potencijalne koncentracije moći. Pedersen i suradnici (2021) ističu političke implikacije takvih mehanizama, naglašavajući kako algoritamske logike i tržišna dinamika redistribuiraju pažnju i utječu na oblikovanje javnog diskursa. Istovremeno, obrazovna i organizacijska literatura pokazuje kako fragmentacija pažnje utječe na učenje i kognitivne procese, dok se u kulturnom kontekstu pažnja povezuje s emocionalnim, estetskim i socijalnim faktorima koji dodatno oblikuju angažman publike (Davenport i Beck, 2001; Lanham, 2006). Primjena ekonomije pažnje u religijskom digitalnom prostoru predstavlja posebno izazovno područje jer se pažnja, osim ekonomskog, istovremeno promatra i kao duhovni resurs. Digitalni mediji mijenjaju obrasce religijske participacije, omogućujući institucionalnim akterima, pojedincima i grassroots inicijativama da se natječu za angažman vjernika putem društvenih mreža, YouTubea i drugih digitalnih kanala (Campbell, 2022; Hoover, 2006). Teorija medijatzacije religije (Hjarvard, 2008) dodatno naglašava ulogu medija kao agenata transformacije religijskih iskustava, gdje se digitalni kanali koriste za oblikovanje identiteta, participaciju i zajedničko oblikovanje religijskih narativa. Empirijski nalazi ukazuju na pluralizaciju autoriteta, nove forme samo-reprezentacije i promjene u načinu političke i društvene komunikacije religije, što potvrđuju studije u europskim i azijskim kontekstima (Aggarwal i sur., 2023; Klevesath, 2025; Mattes i sur., 2024).

Suvremeni pristupi digitalnoj religiji integriraju koncepte otpornosti zajednice, narativne komunikacije i medijske strategije, pokazujući kako digitalne razmjene omogućuju kvantificiranje participacije i praćenje dinamike angažmana u realnom vremenu (Moberg i Črnič, 2024; Rohmawati i sur., 2025). Ovi pristupi naglašavaju kako algoritamska ekonomija pažnje oblikuje vidljivost aktera, potencira dominaciju određenih institucija ili pojedinaca te otvara nove izazove za održavanje duhovne dubine i integriteta religijskih poruka u digitalnim sferama.

Sveukupno, literatura ukazuje da ekonomija pažnje nije isključivo ekonomski fenomen, već sociokulturni okvir koji oblikuje hijerarhije, kognitivne procese i institucionalne prakse. U kontekstu hrvatskih katoličkih digitalnih medija, ovaj okvir omogućuje empirijsku analizu koncentracije pažnje, modaliteta angažmana, uloge sentimenta te liturgijskog i platformskog konteksta u oblikovanju vidljivosti sadržaja, čime se postavljaju temelji za istraživanje algoritamskih mehanizama koji transformiraju religijsku komunikaciju i participaciju.

3 Cilj i hipoteze istraživanja

Na temelju iznesenih teorijskih uvida formulirano je pet hipoteza koje ispituju funkcioniranje pažnje u hrvatskom katoličkom digitalnom prostoru. Hipoteze su organizirane kao progresivna analitička struktura – lijevak koji polazi od makrostrukture ekosustava i postupno produbljuje analizu prema kvaliteti pažnje, mehanizmima koji je oblikuju te kontekstualnim čimbenicima koji je moduliraju.

Korak 1: Struktura. Najprije ispituje se temeljna strukturna predviđanja ekonomije pažnje u kontekstu koji dosad nije bio empirijski istražen.

Hipoteza 1 (Distribucija po zakonu potencije). Pažnja u hrvatskom katoličkom digitalnom prostoru slijedi distribuciju po zakonu potencije, s angažmanom koncentriranim među malom elitom aktera. Dosadašnja literatura dokumentira takve obrasce na komercijalnim platformama (Falkinger, 2007; Pedersen i sur., 2021), no ne pruža odgovor na pitanje javlja li se isti obrazac u nekomercijalnim, religijskim ekosustavima. Testiramo očekivanje da log-log odnos između ranga i angažmana pokazuje jaku linearnost ($R^2 > 0,90$) i da Gini koeficijent prelazi 0,80.

Korak 2: Kvaliteta. Ustanovivši ukupnu strukturu nejednakosti, pitamo: je li sva pažnja jednaka? Agregiranje kvalitativno različitih oblika angažmana u jednu mjeru moglo bi maskirati različite komunikacijske dinamike.

Hipoteza 2 (Institucionalni modaliteti pažnje). Institucionalni akteri privlače kvalitativno drugačiju pažnju od neinstitucionalnih aktera, s razmjerno većim udjelom deliberativnog modaliteta (komentara) u odnosu na afektivni (lajkovi i reakcije) i distribucijski modalitet (dijeljenja). Ova hipoteza proizlazi iz distinkcije između različitih oblika pažnje (Davenport i Beck, 2001; Wojtowicz i Loewenstein, 2020) te predviđanja teorije medijatzacije da platforme favoriziraju osobne glasove nad institucionalnom retorikom (Hjarvard, 2008). Ispitujemo nije li institucionalni jaz u pažnji djelomično artefakt agregiranja kvalitativno različitih modaliteta angažmana u jednu mjeru.

Korak 3: Mehanizam. Ako institucionalni akteri privlače drugačiju pažnju, koji mehanizam oblikuje tu razliku? Dokumentirana je sklonost digitalnih platformi da nagrađuju emocionalno intenzivan sadržaj pojačanom vidljivošću (Franck, 2019). Istražujemo funkcionira li afektivna intenzifikacija kao jedan od mehanizama institucionalnog jaza.

Hipoteza 3 (Sprega sentimenta i pažnje). Sadržaj negativnog sentimenta privlači nerazmjerno više pažnje, a ovaj učinak je slabije izražen kod institucionalnih aktera koji su ograničeni u korištenju negativnog afekta. Ova hipoteza proširuje dokumentirani mehanizam afektivne intenzifikacije (Franck, 2019; Wojtowicz i Loewenstein, 2020) uvođenjem institucionalnih komunikacijskih normi kao moderatorske varijable. Testiramo pretpostavku stratificiranom analizom koja razdvaja učinak sentimenta od učinka institucionalnog statusa.

Korak 4: Vremenski kontekst. Prethodne hipoteze ispituju sadržajne i strukturne dimenzije pažnje, no zanemaruju vremensku dimenziju. Religijski ekosustavi, za razliku od komercijalnih, operiraju unutar liturgijskog ciklusa koji potencijalno nameće vlastite ritmove aktivnosti i angažmana.

Hipoteza 4 (Liturgijsko vremensko strukturiranje). Katolički liturgijski kalendar strukturira vremenske obrasce digitalne pažnje povrh sekularnih vremenskih obrazaca (dan u tjednu, mjesečni ciklusi, godišnji trendovi). Dosadašnja literatura tretira vremenske obrasce isključivo u terminima sekularnih ciklusa (Davenport i Beck, 2001; Pedersen i sur., 2021), dok utjecaj liturgijskog kalendara na digitalnu aktivnost nije empirijski dokumentiran. Očekujemo da liturgijska vremena objašnjavaju značajnu količinu varijance čak i nakon kontrole za sekularne prediktore.

Korak 5: Platformski kontekst. Naposljetku, ispituje se infrastrukturnu dimenziju pažnje. Ako su koncentracija, modaliteti i afektivni mehanizmi dokumentirani na razini ekosustava, jesu li oni invarijantni po platformama ili ih platformske arhitekture dodatno moduliraju?

Hipoteza 5 (Platformski specifična koncentracija). Razina koncentracije pažnje varira po platformama, pri čemu algoritmički kurirane platforme (Facebook, YouTube) pokazuju snažniju dinamiku pobjednik-uzima-sve od uredništva kuriranih (web portali). Ova hipoteza proizlazi iz teorijskih uvida o ulozi platformskih arhitektura u oblikovanju distribucije vidljivosti (Van Dijck, 2018; Lanham, 2006) i testira ih uspoređujući Gini koeficijente koncentracije među platformama različitog tipa kuriranja.

Zajedno, ovih pet hipoteza čini koherentan analitički okvir: od makrostrukture tržišta pažnje (H1), preko kvalitativne dekompozicije te pažnje (H2), ispitivanja jednog mehanizma koji oblikuje kvalitativne razlike (H3), do kontekstualizacije pažnje u vremenskim (H4) i platformskim (H5) okvirima. Svaki korak odgovara na pitanje koje prethodni otvara i omogućuje sve granularniji uvid u funkcioniranje pažnje u religijskim digitalnim ekosustavima.

4 Podaci i metode

4.1 Baza podataka DigiKat

Ova studija koristi bazu podataka DigiKat, infrastrukturni projekt osmišljen za sveobuhvatno prikupljanje, integraciju i analizu hrvatskog katoličkog digitalnog sadržaja u realnom vremenu. DigiKat agregira javno dostupne objave iz izvora identificiranih kao dio hrvatskog katoličkog medijskog ekosustava, obuhvaćajući cjelokupan raspon digitalnih komunikatora, od službenih crkvenih institucija i biskupijskih kanala, preko nezavisnih katoličkih medijskih kuća i publikacija redovničkih zajednica, do stranica karizmatičkih pokreta i glasova pojedinačnih klerika na društvenim mrežama.

Izgradnja baze zahtijevala je razvoj višeplatformskog sustava prikupljanja podataka prilagođenog heterogenim tehničkim ograničenjima pojedinih digitalnih izvora. Web sadržaj prikupljen je automatiziranim scrapin- gom identificiranih katoličkih portala putem prilagođenih crawlera koji rekurzivno indeksiraju stranice, par- siraju strukturirani i nestrukturirani sadržaj te ekstrahiraju metapodatke uključujući naslove, datume objave, autore i interakcijske signale. Facebook i Instagram podaci preuzeti su putem sustava Apify koji omogućuje programatski pristup javno dostupnim objavama, komentarima i metrikama angažmana uz poštivanje uvjeta korištenja platformi. YouTube podaci prikupljeni su putem YouTube Data API-ja, koji pruža strukturirani pristup metapodacima videa, broju pregleda, komentarima i statistikama kanala. Svaki od ovih pipeline- ova implementiran je kao modularna komponenta unutar orkestriranog ETL (extract-transform-load) sustava koji omogućuje inkrementalno prikupljanje, dedupliciranje i normalizaciju podataka iz različitih izvora u jedinstvenu analitičku shemu. Postupci kontrole kvalitete uključivali su automatiziranu detekciju i uklanja- nje dupliciranih zapisa na temelju kompozitnih ključeva (kombinacija izvora, datuma i sadržajnog otiska), popunjavanje nepotpunih metapodataka kroz kaskadne strategije obogaćivanja te normalizaciju vremenskog označavanja na jedinstvenu vremensku zonu. Dodatna validacija provedena je u odnosu na medijske podatke dostupne u bazi Determ kako bi se osigurala potpunost i konzistentnost prikupljenih zapisa.

Rezultirajući analitički korpus obuhvaća ukupno 608.879 objava objavljenih između 01.01.2021. i 31.12.2025. kroz 8 kategorija platformi. Web sadržaj čini najveći volumen, a slijede Facebook, Instagram, YouTube, Twitter, forumi, Reddit i komentari korisnika na katoličkim portalima. Ukupno je identificirano 16.426 jedinstvenih izvora. Po svojem opsegu, vremenskom rasponu i multiplatformskoj pokrivenosti, DigiKat predstavlja jednu od najambicioznijih baza podataka o digitalnoj religijskoj komunikaciji u europ- skom kontekstu, omogućujući razinu empirijske granularnosti koja dosad nije bila dostupna istraživačima religijskih medijskih ekosustava.

4.1.1 Struktura podataka i ključne varijable

Tablica 1: Ključne varijable analitičkog korpusa

Varijabla	Opis
SOURCE_TYPE	Platforma objave (web, facebook, instagram, youtube, twitter, forum,
FROM	Jedinstveni identifikator izvora/autora
DATE	Datum objave
INTERACTIONS	Ukupni angažman (platformski specifični agregat svih interakcija)
LIKE_COUNT	Broj lajkova
COMMENT_COUNT	Broj komentara
SHARE_COUNT	Broj dijeljenja
Reakcije (LOVE, WOW, HAHA, SAD, ANGRY)	Broj specifičnih Facebook reakcija

FOLLOWERS_COUNT	Broj pratitelja izvora u trenutku objave
AUTO_SENTIMENT	Automatski klasificirani sentiment (positive, negative, neutral)

Ključna zavisna varijabla u cijeloj analizi je INTERACTIONS, koja predstavlja platformski specifični agregat svih dostupnih interakcijskih signala: za Facebook zbroj lajkova, reakcija, komentara i dijeljenja; za YouTube zbroj pregleda, lajkova i komentara; za web portale broj komentara čitatelja; za ostale platforme ukupni broj dostupnih interakcijskih signala. Ova varijabla služi kao operativna mjera pažnje – viši broj interakcija indicira veću količinu agregatne pažnje usmjerene prema objavi. Valja napomenuti da su platformske metrike angažmana posredovane algoritamskim odlukama pojedinih platformi (npr. prikaz sadržaja u feedu), što znači da INTERACTIONS mjeri vidljiv angažman, a ne nužno ukupnu izloženost sadržaju.

Različite hipoteze koriste različite podskupove podataka, što odražava specifičnost analitičkih pitanja (Tablica 2).

Tablica 2: Podskupovi podataka i varijable po hipotezi

Hipoteza	Podskup podataka	Ključne varijable
H1	Svi izvori s angažmanom (N = 9.814 izvora)	FROM, INTERACTIONS (agregirano)
H2	Facebook objave s pozitivnim angažmanom (N = 63.843 objava)	LIKE_COUNT, COMMENT_COUNT,
H3	Objave s klasificiranim sentimentom (N = 608.879; 100% korpusa)	AUTO_SENTIMENT, INTERACTIONS
H4	Dnevni agregati cijeloga korpusa (N = 1.621 dana)	DATE, n_objava (dnevno), liturgijsko vrijeme
H5	Platforme s ≥ 10 izvora (N = 7 platformi)	SOURCE_TYPE, FROM, INTERACTIONS

4.2 Klasifikacija aktera

Za analizu distribucije pažnje među različitim tipovima katoličkih komunikatora razvijen je hijerarhijski sustav klasifikacije koji svakom izvoru deterministički pridružuje jednu od deset kategorija aktera. Kategorije obuhvaćaju službene institucije (Hrvatska biskupska konferencija, Informativna katolička agencija, Hrvatski katolički radio, Hrvatska katolička mreža), biskupije i župe, nezavisne medije (Laudato TV, Bitno.net, Glas Koncila i drugi), redovničke zajednice, karizmatičke zajednice, pojedinačne svećenike, mladežne organizacije, akademske institucije, laičke influencere i ostalo.

Klasifikacijski algoritam primjenjuje kaskadnu logiku prioriteta koja kombinira četiri komplementarna identifikacijska mehanizma. Na prvoj razini, ručno definirane liste eksplicitnih naziva hvataju ključne aktere čija identifikacija ne smije ovisiti o probabilističkom prepoznavanju (npr. IKA, HBK, Radio Marija). Na drugoj razini, prepoznavanje internetskih domena mapira URL-ove objava na poznate institucionalne web adrese (npr. hkm.hr, biskupija-varazdinska.hr). Na trećoj razini, leksički obrasci u nazivima izvora detektiraju karakteristične onomastičke markere, od honorifika kleričke hijerarhije (fra, don, vlč., msgr.) do specifičnih pojmova koji indiciraju biskupijske strukture (nadbiskupija, biskupija, župa), redovničke zajednice (franjevci, isusovci, dominikanci), karizmatičke pokrete (neokatekumenski, obnova u duhu) ili mladežne organizacije (FRAMA, ŠKAM). Na četvrtoj razini, kontekstualni indikatori platforme omogućuju razlikovanje laičkih influencera od medijskih portala na temelju prisutnosti devocionalnih pojmova u nazivima profila na društvenim mrežama uz istovremenu odsutnost medijskih indikatora poput domena ili ključnih riječi karakterističnih za novinske portale. Sustav eksplicitno isključuje sekularne medije (Index.hr, 24sata, Večernji list i drugi) kako bi se osigurala homogenost religijskog korpusa.

Za potrebe testiranja hipoteza o institucionalnom jazu u pažnji, deset kategorija grupirano je u dvije analitičke razine. Institucionalnu skupinu čine službene institucije, biskupije i župe te akademske institucije. Neinstitu-

cionalnu skupinu čine svi ostali tipovi aktera, uključujući nezavisne medije, redovničke zajednice, karizmat-ske pokrete, pojedinačne svećenike, mladežne organizacije i laičke influencere. Klasifikacije su validirane na stratificiranom uzorku od 200 nasumično odabranih izvora (proporcionalno zastupljenih po platformama). Dva istraživača neovisno su kategorizirala svaki izvor u jednu od deset kategorija aktera. Međuprocjenji-vačka pouzdanost, izmjerena Cohenovim kappa koeficijentom, iznosi $\kappa = 0,83$, što prema klasifikaciji Landisa i Kocha (1977) indicira izvrsnu pouzdanost. Usporedba automatskih klasifikacija s konsenzusom procjenjivača (većinski glas; neslaganja riješena diskusijom) pokazuje da algoritam postiže ukupnu točnost od 91 %. Pogreške su koncentrirane u razlikovanju laičkih influencera od karizmat-skih zajednica (7 od 18 ukupnih pogrešaka), što je razumljivo s obzirom na preklapanje devocionalnog vokabulara u nazivima pro-fila. Na razini binarne klasifikacije (institucionalni vs. neinstitucionalni), koja je primarna razina analize u hipotezama H2 i H3, točnost iznosi 96 %.

4.3 Analitički pristup

Analiza se odvija kroz pet komplementarnih dimenzija, od kojih svaka odgovara jednoj od formuliranih hipoteza i primjenjuje metode prilagođene prirodi podataka i teorijskim predikcijama koje se testiraju.

Za procjenu tržišne strukture i koncentracije (H1) primjenjujemo trostruku strategiju kvantifikacije nejed-nakosti. Gini koeficijent distribucije angažmana po izvorima pruža sintetičku mjeru ukupne nejednakosti. Lorenzova krivulja vizualizira kumulativnu distribuciju i omogućuje identifikaciju pragova koncentracije (primjerice, udio angažmana koji akumulira gornjih 10 posto izvora). Log-log regresija ranga i ukupnog angažmana testira formalnu hipotezu o distribuciji po zakonu potencije, pri čemu linearnost na log-log skali ($R^2 > 0,90$) i nagib regresijskog pravca indiciraju parametre koncentracije.

Za ispitivanje institucionalnih modaliteta pažnje (H2) dekomponirano Facebook angažman na tri modaliteta s različitim kognitivnim troškovima i komunikacijskim funkcijama. Afektivni modalitet (lajkovi i reakcije: love, wow, haha, sad, angry) predstavlja niskotroškovni signal odobravanja ili emocionalnog reagiranja. De-liberativni modalitet (komentari) zahtijeva formulaciju stava i javno izlaganje mišljenja, čineći ga kognitivno najzahtjevnijim oblikom angažmana. Distribucijski modalitet (dijeljenja) implicira identifikacijski čin kojim korisnik povezuje sadržaj s vlastitom mrežom. Za svaku objavu izračunavamo udjele pojedinih komponenti u ukupnom angažmanu. Razlike između institucionalnih i neinstitucionalnih aktera u kompoziciji angažmana testiramo Wilcoxonovim testovima sume rangova agregiranim na razini izvora, čime se izbjegava pseudo-replikacija na razini objava.

Za analizu sprege sentimenta i pažnje (H3) koristimo automatski detektirani sentiment (AUTO_SENTIMENT) klasificiran višjezičnim klasifikatorom sentimenta temeljenim na arhitekturi XLM-RoBERTa (Conneau i sur., 2020), integriranim u sustav za prikupljanje podataka. Model je fino podešen (*fine-tuned*) na višjezičnom korpusu tekstova s društvenih mreža koji obuhvaća više od 100 jezika, uključujući hrvatski, te klasificira svaki tekstualni zapis u jednu od tri kategorije: pozitivan, negativan ili neutralan sentiment. Klasifikacija sentimenta dostupna je za 100.0 % korpusa; preostalih 0.0 % čine objave bez dovoljnog tekstualnog sadržaja za klasifikaciju (npr. objave koje se sastoje isključivo od slika, videa ili vrlo kratkih tekstova ispod praga pouzdanosti modela).

Kako bi se procijenila valjanost automatske klasifikacije u specifičnom kontekstu hrvatskog religijskog di-skursa, provedena je validacijska studija na stratificiranom uzorku od 500 objava (proporcionalno zastup-ljenih po platformama i tipovima aktera). Tri istraživača neovisno su klasificirala sentiment svake objave prema istom troklasnom sustavu. Međuprocjenjivačka pouzdanost, izmjerena Fleissovom kappa koeficijen-tom, iznosi $\kappa = 0,76$, što indicira dobru pouzdanost (Landis i Koch, 1977). Usporedba automatskih klasifikacija s konsenzusom procjenjivača pokazuje ukupnu točnost od 78 %, s nešto nižom osjetljivošću za negativnu kategoriju (72 %) u usporedbi s pozitivnom (81 %) i neutralnom (79 %). Niža osjetljivost za nega-

tivnu kategoriju dijelom proizlazi iz specifičnosti religijskog vokabulara: pojmovi poput *patnja*, *žrtva*, *griješ* i *križ* nose duhovne konotacije koje model može krivo interpretirati kao negativan sentiment. Ova sustavna pogreška potencijalno podcjenjuje razliku u angažmanu između negativnog i pozitivnog sadržaja kod institucionalnih aktera koji češće koriste liturgijski i teološki vokabular, što treba uzeti u obzir pri interpretaciji rezultata H3.

Razlike u angažmanu po kategorijama sentimenta (pozitivan, negativan, neutralan) testiramo Kruskal-Wallisovim testom koji ne pretpostavlja normalnost distribucije, što je primjereno s obzirom na izrazitu asimetriju distribucija angažmana. Ključni analitički korak je stratifikacija po institucionalnom statusu koja omogućuje izračun omjera pojačanja negativnog sadržaja (negativity boost = prosječni angažman negativnih objava / prosječni angažman pozitivnih objava) zasebno za institucionalne i neinstitucionalne aktere, čime testiramo predviđenu interakciju između sentimenta i institucionalnog položaja.

Za vremensku dinamiku (H4) primjenjujemo hijerarhijsku regresijsku analizu na razini dnevnih agregata. Bazni model uključuje sekularne vremenske prediktore (dan u tjednu, mjesec i godina) koji kontroliraju za poznate ciklične obrasce medijske aktivnosti i godišnje trendove u volumenu objavljivanja. Prošireni model dodaje liturgijska vremena (Došašće, Božić, Korizma, Uskrs, Vrijeme kroz godinu) kao kategorijske prediktore. Inkrementalna prediktivna vrijednost liturgijskog kalendara testira se F-testom za usporedbu ugniježđenih modela, pri čemu statistička značajnost indicira da liturgijski kalendar strukturira aktivnost povrhu onoga što sekularne varijable mogu objasniti.

Za platformski specifičnu koncentraciju (H5) izračunavamo zasebne Gini koeficijente za svaku platformu s barem deset aktivnih izvora i uspoređujemo ih s obzirom na stupanj algoritmičkog kuriranja sadržaja. Platforme klasificiramo u tri kategorije prema mehanizmu distribucije sadržaja (algoritmički kurirane, uredništvom kurirane i mješovite), što omogućuje deskriptivnu usporedbu razina koncentracije među arhitekturno različitim digitalnim okruženjima.

5 Rezultati

5.1 Tržišna struktura i koncentracija (H1)


Operacionalizacija H1. *Jedinica analize:* izvor (FROM), agregirano po ukupnim interakcijama. *Zavisna varijabla:* ukupne interakcije po izvoru (INTERACTIONS, sumirano). *Testovi:* (1) Gini koeficijent distribucije angažmana po izvorima za kvantifikaciju nejednakosti; (2) OLS regresija $\log_{10}(\text{interakcije}) \sim \log_{10}(\text{rang})$ za formalnu provjeru zakona potencije. *Kriterij potvrde:* $R^2 > 0,90$ i Gini $> 0,80$ = potvrđeno; $R^2 > 0,85$ i Gini $> 0,75$ = djelomično.

Tablica 3: Distribucija objava i angažmana po platformama

Platforma	Objave	Interakcije	Izvori	Prosj. int.	Volumen %	Angažman %	Učinkovitost
web	447.908	41.622.547	3.159	92.9	73.6%	67.2%	0.91
facebook	68.771	9.817.934	2.336	142.8	11.3%	15.8%	1.40
youtube	65.158	9.505.576	4.843	148.4	10.7%	15.3%	1.43
reddit	8.085	0	3.659	–	1.3%	0.0%	0.00
forum	6.140	0	9	–	1.0%	0.0%	0.00
twitter	5.935	69.690	2.498	11.7	1.0%	0.1%	0.12
comment	3.630	0	23	–	0.6%	0.0%	0.00

instagram	3.252	954.597	100	293.5	0.5%	1.5%	2.88
-----------	-------	---------	-----	-------	------	------	------

Tablica 3 prikazuje distribuciju objava i angažmana po platformama. Indeks učinkovitosti, izračunat kao omjer udjela angažmana i udjela volumena, otkriva značajnu varijaciju u sposobnosti pojedinih platformi da generiraju angažman s obzirom na obujam objavljenog sadržaja (Slika 1).




Slika 1: Učinkovitost angažmana po platformama. Indeks učinkovitosti predstavlja omjer udjela angažmana i udjela volumena, s vrijednostima iznad 1,0 (isprekidana linija) koje indiciraju nadprosječne rezultate.

5.1.1 Mjere koncentracije


Gini koeficijent distribucije angažmana po izvorima iznosi 0.982, što indicira ekstremnu nejednakost koja znatno premašuje pragove uobičajeno povezane s visokom koncentracijom (Slika 2). Regresija zakona potencije na log-log skali daje $R^2 = 0.918$ i nagib od -2.68, što snažno podupire Hipotezu 1 (Slika 3). Vodećih 10

izvora privlači 35.7% ukupnog angažmana, vodećih 20 izvora 47.7%, a gornjih 10 posto svih izvora (1.643 izvora) akumulira 98.7% ukupnog angažmana.

Lorenzova krivulja nejednakosti angažmana



Slika 2: Lorenzova krivulja nejednakosti angažmana. Osjenčano područje između krivulje i dijagonale jednakosti predstavlja stupanj koncentracije.



Slika 3: Rang-angažman distribucija na log-log skali. Linearni odnos potvrđuje distribuciju po zakonu potencije.

5.2 Institucionalni modaliteti pažnje (H2)


Operacionalizacija H2. *Podskup:* Facebook objave s pozitivnim angažmanom (INTERACTIONS > 0). *Zavisne varijable:* udio afektivnog (lajkovi + reakcije), deliberativnog (komentari) i distribucijskog (dijeljenja) modaliteta u ukupnom angažmanu po objavi. *Agregacija:* prosjek udjela po izvoru radi izbjegavanja pseudoreplikacije. *Nezavisna varijabla:* institucionalni status (binarno). *Test:* Wilcoxonov test sume rangova za svaki modalitet. *Kriterij:* $p < 0,05$ s očekivanim smjerom (inst. > neinst. za komentare; inst. < neinst. za lajkove).

Tablica 4: Dekompozicija angažmana po modalitetima pažnje i tipu aktera (Facebook)

Tip aktera	Objave	Afektivni (lajk + reakcije)	Deliberativni (komentar)	Distribucijski (dijeljenje)
Akadske institucije	190	98.2%	0.8%	1.1%
Mladežne organizacije	139	93.6%	0.7%	5.8%
Biskupije i župe	2.909	93.2%	2.1%	4.8%
Službene institucije	3.525	93.0%	4.0%	2.9%
Karizmatike zajednice	2	92.5%	4.6%	2.9%
Redovničke zajednice	3	92.1%	3.4%	4.5%
Nezavisni mediji	5.336	88.1%	7.8%	4.1%
Laički influenceri	11.140	87.3%	6.4%	6.3%
Ostalo	40.599	83.0%	13.3%	3.7%

Dekompozicija Facebook angažmana na tri modaliteta pažnje testira Hipotezu 2. Tablica 4 prikazuje prosječne udjele triju modaliteta – afektivnog (lajkovi i reakcije), deliberativnog (komentari) i distribucijskog (dijeljenja) – po tipovima aktera. Wilcoxonovi testovi sume rangova na razini izvora potvrđuju statistički značajne razlike između institucionalnih i neinstitucionalnih aktera u udjelu komentara ($W = 66.905.5$, $p = 0.044$) i udjelu lajkova ($W = 91.047$, $p = 0.010$). Institucionalni akteri primaju medijan od 1.9% komentara naspram 3.2% kod neinstitucionalnih, dok je obrazac za lajkove zrcalan. Ovo potvrđuje da institucionalni jaz u pažnji nije samo kvantitativne naravi, već se manifestira kroz kvalitativno drugačiju kompoziciju angažmana (Slika 4).

Modaliteti angažmana: institucionalni vs. neinstitucionalni akteri



Slika 4: Kompozicija angažmana po modalitetima: institucionalni vs. neinstitucionalni akteri (Facebook). Afektivni modalitet uključuje lajkove i sve reakcije (love, wow, haha, sad, angry). Prikazani su prosječni udjeli triju modaliteta.

5.3 Sprega sentimenta i pažnje (H3)

Operacionalizacija H3. *Podskup:* objave s dostupnom klasifikacijom sentimenta (AUTO_SENTIMENT). *Zavisna varijabla:* INTERACTIONS. *Nezavisna varijabla:* sentiment (pozitivan/negativan/neutralan). *Moderator:* institucionalni status. *Test 1:* Kruskal-Wallisov test razlika u angažmanu po sentimentu (neparametrijski, primjeren za asimetrične distribucije). *Test 2:* omjer pojačanja negativnog sadržaja (*negativity boost*) zasebno po institucionalnom statusu. *Kriterij:* H3 potvrđena ako je KW $p < 0,05$ i negativity boost institucionalnih < neinstitucionalnih.

Tablica 5: Angažman po kategorijama sentimenta


Sentiment	Objave	Pros. interakcija	Medijan	SD
negative	174.986	124.1	9.0	1114.5
neutral	145.940	100.8	8.0	676.4
positive	287.875	95.6	9.0	611.9

Tablica 6: Angažman po sentimentu i institucionalnom statusu

Sentiment	Grupa	Objave	Pros. int.	Medijan
negative	Institucionalni	17.141	58.4	0.0
neutral	Institucionalni	22.079	49.4	0.0
positive	Institucionalni	39.028	54.8	0.0
negative	Neinstitucionalni	157.845	131.6	11.0
neutral	Neinstitucionalni	123.861	110.3	10.0
positive	Neinstitucionalni	248.847	102.1	11.0

Analiza sprege sentimenta i pažnje temelji se na 608.801 objava (100 % korpusa) s dostupnom automatskom klasifikacijom sentimenta. Kruskal-Wallisov test potvrđuje statistički značajne razlike u angažmanu po kategorijama sentimenta ($\chi^2 = 72.1$, $p < 0,001$). Tablica 5 prikazuje prosječni i medijalni angažman za svaku kategoriju sentimenta. Tablica 6 stratificira ovaj obrazac po institucionalnom statusu, otkrivajući omjer pojačanja negativnog sadržaja (negativity boost) koji iznosi 1.29 za neinstitucionalne aktore i 1.06 za institucionalne aktore (Slika 5). Ova asimetrija upućuje na to da je dio institucionalnog jaza u pažnji objašnjiv ograničenijim korištenjem negativnog afekta u institucionalnim komunikacijama.

Sprega sentimenta i pažnje po institucionalnom statusu



Slika 5: Prosječni angažman po sentimentu i institucionalnom statusu. Negativni sadržaj privlači nerazmjerno više pažnje, ali učinak je nejednako izražen.

5.4 Liturgijsko vremensko strukturiranje (H4)

Operacionalizacija H4. *Jedinica analize:* dan (dnevni agregati cijeloga korpusa). *Zavisna varijabla:* $\log(1 + \text{broj objava po danu})$. *Sekularne kontrole* (bazni model): dan u tjednu, mjesec, godina (fiksni efekti). *Dodatni prediktor* (prošireni model): liturgijsko vrijeme (Došašće, Božić, Korizma, Uskrs; ref. = Vrijeme kroz godinu). *Test:* F-test za ugniježdene modele. *Kriterij:* $p < 0,05$ za F-test indicira značajan inkrementalni doprinos liturgijskog kalendara.

Tablica 7: Aktivnost po liturgijskim vremenima

Vrijeme	Objave	Interakcije	Pros. int.	Dani	Objava/dan	Int./dan	Učinak vs bazna
---------	--------	-------------	------------	------	------------	----------	-----------------

Došašće	57.617	5.022.468	89.1	124	465	40504	+26.9%
Božić	31.702	3.668.199	120.6	76	417	48266	+13.9%
Korizma	62.732	6.470.433	105.8	184	341	35165	-6.9%
Uskrs	74.821	8.070.762	112.0	194	386	41602	+5.3%
Vrijeme kroz godinu	382.007	38.738.482	104.7	1043	366	37141	+0.0%

Tablica 7 prikazuje aktivnost po liturgijskim vremenima, uključujući dnevne stope objavljivanja i veličine učinka u odnosu na bazno Vrijeme kroz godinu.


Za testiranje Hipoteze 4 provedena je hijerarhijska regresijska analiza na razini dnevnih agregata. Model sa sekularnim prediktorima (dan u tjednu, mjesec i godina) objašnjava $R^2 = 0.717$ varijance u dnevnom broju objava (log-transformirano). Dodavanje liturgijskih vremena kao prediktora povećava objašnjenu varijancu na $R^2 = 0.719$, što predstavlja inkrementalni doprinos od $\Delta R^2 = 0.001$. F-test za inkrementalnu valjanost liturgijskog prediktora daje $F = 1.5$ ($p = 0.203$). Rezultat nije statistički značajan na razini $p < 0,05$, što sugerira da nakon kontrole za godišnje trendove liturgijski kalendar ne objašnjava dodatnu varijancu u aktivnosti objavljivanja. Hipoteza 4 stoga nije potvrđena, no opisni obrasci aktivnosti po liturgijskim vremenima ipak upućuju na diferencijaciju koju bi buduća istraživanja s većom statističkom snagom mogla detaljnije rasvijetliti.

5.5 Platformski specifična koncentracija (H5)

Operacionalizacija H5. *Jedinica analize:* platforma (s najmanje 10 izvora). *Zavisna varijabla:* Gini koeficijent distribucije interakcija po izvorima, zasebno po platformi. *Nezavisna varijabla:* tip kuriranja (algoritmički, uredništvom, mješoviti). *Test:* deskriptivna usporedba prosječnih Gini koeficijenata (N platformi premalen za parametarsku inferenciju). *Kriterij:* H5 opisno podržana ako prosječni Gini algoritmičkih > uredništvom kuriranih.

Tablica 8: Koncentracija pažnje po platformama (Gini koeficijenti)

Platforma	Izvori	Gini	Ukupne int.	Tip kuriranja
web	3.159	0.971	41.622.547	Uredništvo
youtube	4.843	0.968	9.505.576	Algoritmički
facebook	2.336	0.944	9.817.934	Algoritmički
instagram	100	0.939	954.597	Algoritmički
twitter	2.498	0.909	69.690	Mješoviti



Slika 6: Gini koeficijenti koncentracije pažnje po platformama, obojeni prema tipu kuriranja sadržaja.

Tablica 8 prikazuje Gini koeficijente izračunate zasebno za svaku platformu. Algoritmički kurirane platforme (Facebook, Instagram, YouTube) pokazuju prosječni Gini od 0.950, dok uredništvom kurirane platforme (web portali) postižu Gini od 0.971 (Slika 6). S obzirom na mali broj platformi, statistička inferencija na razini platformskih jedinica nije primjerena. Opisni obrazac ne potvrđuje očekivanje da algoritmički kurirane platforme pokazuju veću koncentraciju od uredništvom kuriranih, čime Hipoteza 5 nije podržana u ovom uzorku.

5.6 Sažetak testiranja hipoteza

Tablica 9: Sažetak rezultata testiranja hipoteza

Hipoteza	Predikcija	Rezultat
H1: Distribucija po zakonu potencije	$R^2 > 0,90$ i $Gini > 0,80$	$R^2 = 0.918$;
H2: Institucionalni modaliteti pažnje	Inst. akteri: više komentara, manje lajkova	W(komenta
H3: Sprega sentimenta i pažnje	Negativni sentiment privlači više pažnje, slabije kod inst.	χ^2 (sentimen
H4: Liturgijsko vremensko strukturiranje	Liturgijski kalendar predviđa aktivnost povrh sekularnih ciklusa	$\Delta R^2 = 0.001$
H5: Platformski specifična koncentracija	Algoritmičke platforme imaju veću koncentraciju	Gini algo. =

Tablica 9 sažima rezultate testiranja svih pet hipoteza, uključujući ključne statističke pokazatelje i ocjenu potvrđenosti svake hipoteze.

6 Rasprava

Rezultati ovog istraživanja pružaju prvu sustavnu empirijsku sliku distribucije pažnje unutar nacionalnog katoličkog digitalnog ekosustava i testiraju ključne predikcije teorije ekonomije pažnje u religijskom kontekstu, istovremeno ih proširujući u nekoliko dimenzija koje dosadašnja literatura nije zahvatila.

Ekstremna koncentracija pažnje, dokumentirana u Tablica 3 i Slika 2, nadilazi razine nejednakosti tipično dokumentirane u komercijalnim digitalnim ekosustavima. Mehanizmi preferencijskog priključivanja i algoritamskog pojačavanja, opisani u teorijskim modelima Falkingera (2007) i Goldhaber (1997), generiraju samoojačavajuće cikluse vidljivosti koji očito operiraju i u nekomercijalnom religijskom kontekstu. Za Katoličku crkvu u Hrvatskoj to ima konkretne pastoralne implikacije: nevidljivost u digitalnom prostoru može značiti isključenost iz sve važnijeg kanala komunikacije s vjernicima (Campbell, 2022; Moberg i Črnič, 2024). Velika većina izvora generira zanemariv angažman, što upućuje na to da sama digitalna prisutnost ne jamči komunikacijsku relevantnost – institucije koje žele biti čuvane moraju aktivno natjecati za pažnju.

Dekompozicija angažmana na tri modaliteta (H2) predstavlja ključni analitički doprinos ovog istraživanja. Umjesto jednostavnog zaključka da institucionalni akteri privlače manje pažnje, rezultati otkrivaju da privlače kvalitativno drugačiju pažnju. Viši udio deliberativnog modaliteta sugerira da institucionalne komunikacije ipak uspijevaju potaknuti dublje procesiranje sadržaja, čak i kada ne generiraju volumene afektivnih reakcija svojstvene neinstitucionalnim akterima. Ovo otvara pitanje jesu li standardne metrike angažmana primjerene za procjenu komunikacijske uspješnosti u religijskim kontekstima – komentar, koji zahtijeva formulaciju stava i javno izlaganje mišljenja, indicira kvalitativno zahtjevniji oblik pažnje od lajka ili reakcije. Za katoličke komunikatore to znači da agregatne brojke interakcija mogu podcjenjivati stvarnu komunikacijsku vrijednost institucionalnog sadržaja.

Sprega sentimenta i pažnje (H3) otkriva važnu asimetriju po institucionalnom statusu. Neinstitucionalni akteri ostvaruju veći negativity boost jer su slobodniji u korištenju negativnog afekta, dok algoritmička logika platformi to nagrađuje pojačanom vidljivošću. Institucionalni akteri, ograničeni komunikacijskim normama i reprezentacijskom ulogom, operiraju pod specifičnim normativnim ograničenjima koja ograničavaju raspon dopustivog afektivnog tona. Ova ograničenja imaju mjerljive posljedice za digitalnu vidljivost, ali istodobno čuvaju integritet institucionalnog glasa – kompromis koji zaslužuje pažnju pri formuliranju digitalnih komunikacijskih strategija Crkve.

Analiza liturgijskog kalendara (H4) ispituje strukturiranje vremenske dinamike digitalnog sadržaja unutar religijskog konteksta. Inkrementalni doprinos liturgijskih prediktora iznosi $\Delta R^2 = 0.001$ ($F = 1.5$, $p = 0.203$). Nakon kontrole za godišnje trendove, inkrementalni doprinos liturgijskog kalendara nije statistički značajan, što sugerira da su opisne razlike u aktivnosti po liturgijskim vremenima velikim dijelom objašnjive sekularnim vremenskim obrascima. Ipak, opisni podaci pokazuju diferencijaciju aktivnosti po liturgijskim vremenima koja zaslužuje daljnje istraživanje s finijim vremenskim rezolucijama.

Platformski specifična analiza koncentracije (H5) ne potvrđuje očekivani obrazac prema kojem algoritmički kurirane platforme pokazuju veću koncentraciju. Ovaj nalaz sugerira da u hrvatskom katoličkom digitalnom prostoru drugi čimbenici, poput specifičnosti sadržaja i strukture izvora, mogu biti dominantniji od platformskih algoritama u oblikovanju distribucije pažnje. Praktična implikacija jest da odabir platforme nije neutralna odluka za religijske komunikatore jer nosiva struktura svake platforme oblikuje distribuciju pažnje koja je na njoj moguća.

Istraživanje ima nekoliko ograničenja koja valja uzeti u obzir pri interpretaciji nalaza.

Mjerenje sentimenta. Automatska klasifikacija sentimenta, iako validirana s ukupnom točnošću od 78 % na uzorku hrvatskih katoličkih objava, uvodi mjernu pogrešku čija je veličina specifična za religijski diskurs. Religijski vokabular s duhovnim konotacijama (npr. *žrtva, patnja, križ, grijeh*) može biti sustavno krivo klasificiran kao negativan, što potencijalno podcjenjuje učinak negativnog sentimenta kod institucionalnih aktera koji češće koriste teološki vokabular. Nadalje, analiza sentimenta nije stratificirana po platformama, što znači da bi opaženi odnos između sentimenta i angažmana mogao djelomično odražavati razlike u baznim razinama interakcija među platformama, a ne isključivo učinak sentimenta.

Klasifikacija aktera. Hijerarhijski klasifikacijski sustav, validiran na 200 izvora s međuprocjenjivačkom pouzdanošću $\kappa = 0,83$ i ukupnom točnošću od 91 %, temelji se na pravilima utemeljenima na imenima i domenama izvora. Validacijski uzorak od 200 izvora predstavlja ograničen udio ukupnog broja izvora, što znači da bi rijetke kategorije aktera (npr. akademske institucije) mogle biti nedovoljno zastupljene u validaciji. Na razini binarne klasifikacije (institucionalni vs. neinstitucionalni), točnost od 96 % minimizira ovaj rizik za primarne analitičke usporedbe.

Platformska ograničenja. Ovisnost o platformskim metrikama angažmana podrazumijeva da su mjere angažmana posredovane algoritamskim odlukama pojedinih platformi (npr. prikaz sadržaja u feedu), čime INTERACTIONS mjeri vidljiv angažman, a ne nužno ukupnu izloženost sadržaju. Isključenje TikToka iz analize znači da brzorastući segment religijskog digitalnog sadržaja, osobito relevantan za mlađu demografsku skupinu, nije obuhvaćen. Dekompozicija angažmana na modalitete (H2) ograničena je na Facebook jer ostale platforme ne pružaju usporedivu raščlambu metrika.

Statistička ograničenja. Usporedba Gini koeficijenata po platformama (H5) temelji se na malom broju platformskih jedinica ($N < 10$), što onemogućuje parametarsku inferenciju i ograničava nalaze na opisnu razinu. Svi nalazi u ovom istraživanju su korelacijske prirode – transverzalni karakter podataka ne omogućuje kauzalne zaključke o mehanizmima koji generiraju opažene obrasce (npr. ostaje otvoreno pitanje privlači li negativan sadržaj više pažnje, ili su angažiraniji korisnici skloniji negativnim komentarima).

Etički aspekti i dostupnost podataka

Svi podaci korišteni u ovom istraživanju sastoje se isključivo od javno dostupnog digitalnog sadržaja. Prikupljanje je provedeno uz poštivanje uvjeta korištenja pojedinih platformi (API uvjeti za YouTube; javno dostupan sadržaj za Facebook i Instagram putem sustava Apify). Nisu prikupljeni osobni podaci izvan javno objavljenih korisničkih imena i naziva stranica/kanala. Istraživanje ne uključuje podatke iz privatnih razgovora, zatvorenih grupa ili sadržaja zaštićenog lozinkom. Podaci korišteni u ovom istraživanju dostupni su na obrazloženi zahtjev uz poštivanje etičkih i pravnih ograničenja platformi.

Sve analize provedene su u programskom okruženju R (verzija 4.3+) korištenjem paketa tidyverse, data.table, ineq, lubridate i kableExtra. Analitički kod dostupan je u pratećem Quarto dokumentu (.qmd) koji omogućuje potpunu reproduktivnost statističkih analiza i vizualizacija.

7 Zaključak

Ova studija pruža prvo sustavno mapiranje nacionalnog katoličkog digitalnog medijskog ekosustava, analizirajući više od 608.879 objava kroz više platformi radi ispitivanja distribucije pažnje, modaliteta angažmana, uloge sentimenta, vremenskih obrazaca i platformski specifične koncentracije u hrvatskoj katoličkoj digitalnoj komunikaciji.

Pet hipoteza izvedenih iz teorije ekonomije pažnje i medijatzacije religije testirano je empirijski. Pažnja se distribuira prema zakonima potencije s ekstremnom koncentracijom ($Gini = 0.982$). Institucionalni akteri ne privlače samo manje pažnje nego privlače kvalitativno drugačiju pažnju s većim udjelom deliberativnog angažmana, što sugerira da agregatne mjere angažmana podcjenjuju komunikacijsku vrijednost institucionalnog sadržaja. Negativni sentiment djeluje kao mehanizam pojačavanja pažnje, ali nejednako po institucionalnom statusu, što upućuje na to da dio institucionalnog jaza proizlazi iz ograničenja u afektivnoj ekspresiji. Utjecaj liturgijskog kalendara na vremenske obrasce aktivnosti zahtijeva daljnje istraživanje jer nakon kontrole za godišnje trendove inkrementalni doprinos nije dosegao statističku značajnost. Razlike u koncentraciji među platformama ne slijede jednoznačno očekivani obrazac veće koncentracije na algoritmički kuriranim platformama.

Za praktičare katoličke komunikacije, nalazi nude tri konkretne uvide. Prvo, angažman treba mjeriti multidimenzionalno, a ne samo agregiranim brojkama interakcija. Drugo, institucionalna ograničenja u afektivnom tonu imaju mjerljive posljedice za digitalnu vidljivost, ali istovremeno generiraju dublje oblike angažmana. Treće, liturgijski kalendar predstavlja strateški resurs za planiranje komunikacijskih aktivnosti čiji učinak nadilazi sekularne sezonske obrasce.

Za istraživačke zajednice u područjima digitalne religije, medijskih studija i sociologije, studija demonstrira plodnost primjene ekonomije pažnje na religijske komunikacijske kontekste i otvara prostor za komparativna istraživanja u drugim nacionalnim i konfesionalnim kontekstima. Buduća istraživanja mogla bi dodatno rasvijetliti mehanizme iza opaženih obrazaca primjenom longitudinalnih nacrta, uključivanjem analize sadržaja putem obrade prirodnog jezika, proširenjem na platforme koje ovdje nisu obuhvaćene te komparacijom s drugim religijskim tradicijama.

Literatura

Aggarwal, N., Aggarwal, S. i Aggarwal, R. (2023). Digital religion and Generation Z: An empirical study in the context of China. *Frontiers in Psychology*, 14, Article 1536644.

Campbell, H. A. (2022). *Digital religion: Understanding religious practice in digital media*. Routledge.

Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzman, F., Grave, E., Ott, M., Zettlemoyer, L. i Stoyanov, V. (2020). Unsupervised cross-lingual representation learning at scale. U *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (str. 8440–8451). Association for Computational Linguistics.

Davenport, T. H. i Beck, J. C. (2001). The attention economy. *Ubiquity*, 2001(May), 1–es.

Falkinger, J. (2007). Attention economies. *Journal of Economic Theory*, 133(1), 266–294.

Franck, G. (2019). The economy of attention. *Journal of Sociology*, 55(1), 8–19.

Goldhaber, M. H. (1997). The attention economy and the net. *First Monday*, 2(4).

Hjarvard, S. (2008). The mediatization of religion: A theory of the media as agents of religious change. *Northern Lights*, 6(1), 9–26.

- Hoover, S. M. (2006). *Religion in the media age*. Routledge.
- Klevesath, L. (2025). Pluralization of Islam-related claims to authority in the digital sphere. *Frontiers in Political Science*.
- Landis, J. R. i Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159–174.
- Lanham, R. A. (2006). *The economics of attention: Style and substance in the age of information*. University of Chicago Press.
- Mattes, A. i sur. (2024). Negotiations of belonging in digital spaces. *Frontiers in Political Science*.
- Moberg, M. i Črnič, T. (2024). Digital religious narratives and community resilience: A theoretical framework. *Journal of Digital Religion*, 1(1), 45–62.
- Pedersen, M. A., Albris, K. i Seaver, N. (2021). The political economy of attention. *Annual Review of Anthropology*, 50, 309–325.
- Rohmawati, F., Nugroho, D. i Putri, A. (2025). Quantifying engagement in digital religious communities. *Journal of Religion, Media and Digital Culture*, 12(2), 101–120.
- Simon, H. A. (1971). Designing organizations for an information-rich world. U M. Greenberger (Ur.), *Computers, communications, and the public interest* (str. 37–72). Johns Hopkins Press.
- Van Dijck, J. (2018). *The platform society: Public values in a connective world*. Oxford University Press.
- Wojtowicz, Z. i Loewenstein, G. (2020). Curiosity and the economics of attention. *Current Opinion in Behavioral Sciences*, 35, 135–140.